

BF16 Attention

前向优化路径报告

A100 上从可运行实现到接近 FlashAttention 的工程复盘

记录范围 2026 年 10 月 7 日至 8 日 项目 Tiny Transformer

本轮优化围绕 BF16 causal attention 前向展开：先修复接口和边界错误，再用独立计时与 NCU 定位开销，逐步调整 tile、预取、寄存器预算、mask 和行内归约。最新用户报告的 prefill 耗时为 42.34 μ s，同轮 SDPA 为 39.27 μ s，差距收敛到 3.07 μ s。

最新 student prefill	同轮 SDPA FlashAttention	剩余耗时差
42.34 μ s	39.27 μ s	3.07 μ s

同轮速度比为 $SDPA / student = 0.93\times$ ；student 的延迟仍高约 7.8%。初始 Graph 记录为 100.42 μ s，后期沿用 Graph 语境的结果下降至 42.34 μ s，端点参考性降幅约 57.8%。该端点比较不等于严格配对实验，测量证据分级见后文。



图 1 优化主线 先保证可比 再以实测选择取舍

汇报应强调的三个结论

- 有效收益来自组合：数据搬运与同步优化建立基础，mask 和 int32 减少标量工作，最后的延迟归约与倒数复用再降低约 9.4% 的阶段耗时。
- 资源指标不是最终目标：更高 occupancy、零 spill、更高 sector 利用率，都不必然使 kernel 更快。
- 已有反例并及时回退：更紧的 launch bounds、shared-memory 输出重排均未获得净收益；base-2 单独实验没有明显收益。

测量场景：A100 80GB PCIe；BF16；B=8、H=12、D=64；prefill Tq=Tk=512；20 次预热、每轮 100 次调用、5 轮采样。

GPU 执行路径的性能演进

下图只列 Graph 或沿用 Graph 语境的记录。灰色为同轮 SDPA，青色为 student；标注“回退”的候选未进入保留路径。图中跳过的 operator 阶段另列下一页，因此相邻条目不能全部解释为单一改动的收益。




图 2 Graph 口径的观测序列 G07 至 G09 带星号表示完整命令未附在结果片段中

对照	变化	结论
G03 → G04 驻留目标 4 → 5	50.61 → 53.16 μs +5.0%	退回目标 4
G03 → G05 base-2	50.61 → 51.11 μs +1.0%	未测出明显收益
G05 → G06 int32	51.11 → 48.71 μs -4.7%	保留
G07 → G09 归约与倒数组组合	46.73 → 42.34 μs -9.4%	最新已测保留版本

证据边界：G07、G08、G09 沿用此前 Graph 测试上下文，但用户贴出的片段只有结果行，没有完整 CLI。本文保留这些结果并明确标记；不据此宣称所有中间改动都被严格隔离，亦不提供缺失的置信区间。

完整算子口径与 decode 改善

operator 计时包含完整 eager 调用，可能包含 CPU 提交造成的 GPU 间隙；它适合回答“调用一次算子需要多久”。下图五条记录均来自未挂 NCU 的 operator 日志。




图 3 Operator 路径 预取与 CTA 改动的收益不能拆成独立百分比

阶段对照	student 延迟下降	说明
O02 → O03	29.5%	预取 CTA 与 fragment 相关组合
O03 → O04	10.1%	mask fast path 阶段 版本归因有保留
O04 → O05	6.9%	BK 从 32 增至 64
O05 → O06	11.1%	launch bounds 的驻留目标设为 4

单 token decode 采用独立执行路径




图 4 Decode 的 Graph 对照 Tq=1 Tk=512

通用 kernel 为 1 个 query 仍执行 64 行 tile。专用路径按 128 个 key 分块并用 FP32 合并 softmax，Graph 从 34.06 降至 12.73 μ s，快 2.68 倍，同轮达到 SDPA 的 1.21 $\times$ 速度。适用范围为 Tq=1、Tk $\leq$ 4096，不计入 prefill 收益。

Tile 与流水线如何演化

最终保留的主线遵循 Q 整块保留在 shared memory、P 和 O 在寄存器的设计。K/V 从特征 subtile 发展到完整 head-dimension tile，以更多共享内存换取较少的阶段切换。

配置阶段	Q 与 KV 存储	共享内存每 CTA	状态
初始模板	Q 8 KiB P 8 KiB K 与 V 各两份完整 tile	48 KiB	正确性起点
Q 常驻寄存器候选	Q 借用 V 缓冲后进入寄存器 P 改为寄存器转换	32 KiB	未单独验证收益 后续放弃
BK32 BH32	Q 8 KiB 两个 K/V union stage 各 2 KiB	12 KiB	资源压缩探索
BK64 BH32	Q 8 KiB 两个 union stage 各 4 KiB	16 KiB	减少 KV 迭代
BK64 BH64	Q 8 KiB K 8 KiB V 8 KiB K/V 两个完整 slot	24 KiB	最终已测布局




图 5 以更大的特征 tile 减少同步切换

BK=32→64 时，T=512 每个 head 的 KV tile 处理总数从 72 降到 36。BH=32→64 时，去掉 DH 方向的两段循环；每个 CTA 处理 N 个 KV 块的同步总数从 4N 降到 2N，含 prologue 和最后一轮收尾。S/P/O 的大小在 BH 变化时不变，但 PV 临时 B fragment 会增大。

K/V 行宽改变时必须同步修改 swizzle。32-BF16 行最终使用 Swizzle<2,3,3>，64-BF16 行使用 Swizzle<3,3,3>。错误的 Swizzle<2,3,2> 保持了数值布局可逆性，却让相隔四行的片段发生 bank 冲突。

减少非 MMA 指令的关键收益

完整合法块跳过逐元素 mask

在 query tile 和 key tile 都完整、且最早 query 已能看到该 key 块最后位置时，整个 tile 无需 causal 判断。其余块保留逐元素检查。BK=64、T=512 时，每个 head 的 36 个 KV tile 中有 28 个完整合法块。该阶段 operator 从 69.90 降到 62.86 μ s，约改善 10.1%，但与 N=8 展开回撤的版本对应尚未完全固化。

用 int32 表达索引 保留 int64 地址偏移

tile 计数、行列坐标与 mask 比较改用 int32；host 在连续化与分配前检查 $T_k \leq \text{INT32_MAX}$ 。row×DH 和 batch/head 偏移在乘法前提升为 int64。因果比较写成 $kj - \text{past_len} \leq qi$ ，尾块先限长再相加，避免 padded 索引溢出。Graph 从 51.11 降到 48.71 μ s，约改善 4.7%。

分母累计留在线程局部 最后再归约

当前每行由四个 lane 合作。每轮仍计算本 lane 的指数和，并以共同的 alpha 重缩放历史累计值；循环中无需完整行分母，所以可以把跨 lane 求和推迟到末尾。行最大值仍须每轮跨 lane 归约。

同一逻辑行	lane 0	lane 1	lane 2	lane 3
tile 0 后的累计部分和	2	3	4	1
tile 1 新增部分和	1	2	1	4
alpha=0.5 后的累计值	2	3.5	3	4.5

```
for each KV tile:
    l_partial = alpha * l_partial + local_sum

denominator = row_sum(l_partial) # after all KV tiles
inv_l = 1.0f / denominator
O = O_acc * inv_l
```

最终 shuffle 必须由尾块中所有 lane 参与，放在 $qi < Tq$ 判断之前。倒数按每线程负责的每行计算一次，而非更新或保存以前的 S tile。对于遍历 N 个 KV 块的 CTA，分母相关 shuffle 从每线程 4N 次降为 4 次；源码中的输出除法从最多 32 次降为 2 次。

两项一起测量得到 46.73→42.34 μ s，下降 9.4%。没有新增 shared-memory 访问或 CTA barrier；单项收益尚未拆分。浮点求和顺序和除法改写会改变舍入，需要继续使用 FP64 O/LSE 对照。

无收益实验与正确性修复

优化记录保留失败结果，避免在后续迭代中重复追求已经被实测否定的资源指标。下表中的“未隔离”表示不能依据现有日志给出单项速度贡献。

实验	观测	处理
完整 Q 常驻寄存器	减少 shared memory 但增大寄存器工作集 没有可归因的独立提速记录	回到 Q shared memory
手写 N=8 的 B fragment 展开	组合版本 128 registers 20 B spill stores 28 B spill loads	展开回撤 预取和 CTA 排列保留
launch bounds 从 4 提到 5	Graph 50.61→53.16 μ s 慢约 5.0%	采用目标 4
base-2 softmax	Graph 50.61→51.11 μ s 约 1% 差异 未显示明显收益	保留为后续受控基线 不计为独立提速
Q shared memory 重排输出	46.73→48.17 μ s 慢约 3.1%	撤回 直接 32-bit pair 写回
int32 下重试自然指数	曾准备候选 用户明确要求改做 KV tile 没有 GPU 性能结果	未测量 已撤回
更高 occupancy 或零 spill	更多驻留 warp 不保证更低延迟 有少量 spill 的组合版本仍可能更快	按正确性与时间决定

性能实验之前先修复的功能问题

- 绑定与参数：修复 dtype 恒假条件、BF16 类型与指针调用、错误变量名、模板实参；LSE 使用 FP32，启动分配正确的动态共享内存。
- 输入契约：拒绝混合 dtype 和 BF16 segment IDs，检查 SM80 与 grid 上限；连续 view 的 storage_offset 仍可能不对齐，必要时 clone 保证 16-byte 对齐。
- 测试对照：未对齐原始 view 仍交给 student；SDPA 参考使用值相同的对齐副本。一次 CUDA misaligned-address 错误可能污染后续用例，需新进程重跑。
- 编译兼容：坐标 tensor 的 ScaledBasis stride 不能直接用于 fragment 排序，改为取 shape 后分配；误用 `_exp2f` 改为 CUDA 支持的 `exp2f`。

Profiler 证据如何改变判断

证据	观测	工程判断
Shared-load bank conflict	曾占 shared wavefronts 43.60% 修正 swizzle 后用户确认排除	地址模式确有问题 但不是全部耗时来源
Global store sector 有效字节	约 8.19→16.2 / 32 bytes	32-bit pair 写回改善合并 更大重排仍可能得不偿失
Warp 等待	Short Scoreboard 约 0.83→0.32 Long Scoreboard 在后续版本约 1.23→0.74	分别与 shared 冲突缓解 和加载重叠方向一致
Occupancy	理论 25% 一次实测 23.73% 15.19 active warps/SM	接近该版资源上限 不等于始终有可发射 warp
Tail effect	768 CTA 108 SM 4 CTA/SM 432+336 两波	50% 提示不是 50% 可消除耗时 causal CTA 时长也不均匀

编译资源必须按 kernel 和版本匹配

BF16 forward 阶段	Registers	Stack B	Spill store/load B
修正 swizzle 后的一版	约 120 至 121	0	0 / 0
N=8 展开等组合	128	16	20 / 28
BK64 BH32	157	0	0 / 0
launch bounds 4	128	0	0 / 0
int32 base-2	128	8	4 / 4
BH64 完整 K/V	121	0	0 / 0
最新延迟归约与倒数版本	未提供	未提供	未提供

早期日志中的 96 registers 属于 FP32 attention_detail::forward，不是 BF16 kernel。used 1 barriers 表示 barrier 资源，不是动态执行一次同步。24 KiB 属于动态共享内存，未必出现在 ptxas 的静态 smem 字段中。

当前 128-thread CTA 在 A100 上约 121/128 registers 时，寄存器分配限制为 4 CTA/SM；157 registers 时约为 3 CTA/SM。NCU 的估计加速百分比不能相加，stall 图的周期/指令也不能直接当作总耗时占比。

完整测量记录与口径标记

所有数值均取自用户粘贴的终端结果，单位 μs 。G 为 Graph，G* 为沿用 Graph 语境但缺少完整命令的结果片段，O 为 operator，X 为挂 NCU 的诊断运行。X 项仅解释测量干扰，不纳入加速结论。

ID	方式 场景	阶段	student	SDPA	速度比
O01	O/P	最初可运行 BF16	101.92	40.92	0.40×
D01	O/D	通用 query tile	35.44	30.15	0.85×
G01	G/P	初始 Graph 对照	100.42	39.37	0.39×
D02	G/D	通用 query tile	34.06	15.42	0.45×
G02	G/P	小 KV tile 与 union	98.08	39.29	0.40×
D03	G/D	专用 split KV	12.73	15.44	1.21×
X01	X/P	仅一次预热和采样	209.92	258.05	1.23×
X02	X/P	恢复 20 100 5 采样	102.79	158.28	1.54×
O02	O/P	无 NCU 复测	99.10	41.19	0.42×
O03	O/P	预取与 CTA 组合优化	69.90	41.25	0.59×
O04	O/P	完整块 mask fast path	62.86	41.11	0.65×
O05	O/P	BK 从 32 增至 64	58.51	41.31	0.71×
O06	O/P	launch bounds 4	52.03	41.18	0.79×
G03	G/P	launch bounds 4	50.61	39.52	0.78×
G04	G/P	launch bounds 5 回退	53.16	39.26	0.74×
G05	G/P	base 2 softmax	51.11	39.39	0.77×
G06	G/P	int32 索引	48.71	39.23	0.81×
G07	G*/P	BH 从 32 增至 64	46.73	39.35	0.84×
G08	G*/P	shared O 重排 回退	48.17	39.27	0.82×
G09	G*/P	延迟归约与倒数复用	42.34	39.27	0.93×

P=prefill，D=decode。速度比始终为 SDPA/student，大于 1 表示 student 更快。多个结果写入同一 JSON 路径，原始 trial 数组未完整保留在对话中，因此本报告不提供误差条或显著性检验。

复现方式与后续实验

汇报与复测环境为 A100 80GB PCIe、PyTorch 2.8.0a0+34c6371d24.nv25.08。用户 profiler 已确认 prefill 与 decode 都经过 `aten::_scaled_dot_product_flash_attention`。其具体 tile 配置不能仅由这个 ATen 名称推断。

固定输入与计时方式

```
TORCH_CUDA_ARCH_LIST=8.0 python3 -m tiny_transformer.benchmarks \
  --operator attention --backend student --baseline sdpa \
  --precision bf16 --device cuda:1 --phases forward \
  --workloads prefill --attention-timing graph \
  --layouts contiguous --batch-size 8 --heads 12 \
  --dim 768 --seq-length 512 --warmup 20 --repeats 100 --trials 5 \
  --output runs/attention-delayed-denom-graph.json
```

operator 与 Graph 分别报告；不在挂 NCU 的 benchmark 输出中判断谁更快。NCU 内核 Duration 和硬件计数器用于定位问题，无 NCU 的独立运行用于速度结论。缺少 TORCH_CUDA_ARCH_LIST 可能改变 JIT 编译架构并触发重新编译，编译等待不计入稳态计时。

正确性与编译资源

```
TORCH_CUDA_ARCH_LIST=8.0 TINY_TRANSFORMER_CUDA_VERBOSE=1 \
python3 -m unittest discover -s tests \
  -p test_student_attention.py -k bf16 -v
```

再运行 compute-sanitizer 的 memcheck、racecheck、synccheck。已有测试覆盖 FP64 O/LSE、因果隔离、query/key 尾块、非连续和未对齐 view、非默认 stream、Graph 重放与溢出拒绝。报告主机无 CUDA；本地模型与跳过的 GPU 测试不能替代目标设备验收。

保留版本和待验证工作

最新已报告 42.34 μ s 对应“延迟归约与倒数复用”阶段，Git 记录为 8732172；其最终 ptxas 和完整 sanitizer 结果尚未在对话提供。生成报告时，工作区另有未提交的 PV 寄存器双缓冲实验，不计入 42.34 μ s 的收益。下一轮应只比较 PV 的 Idmatrix 提前加载，保持 tile、softmax、bounds 和输出路径一致。40 KiB 完整 K/V 双缓冲与 128 $\times$ 128 大 tile 仅为备选，未得到本次测量验证。

源码依据与数据来源

FlashAttention v2.8.3 softmax 延迟分母归约与最终倒数

FlashAttention v2.8.3 utils Idmatrix 与 MMA 交错

Triton v3.4.0 官方 fused attention 教程 OpenAI kernel team

本地依据：csrc/attention/development.md、attention_forward_BF16_kernel.cuh、tests/test_student_attention.py、Git 提交及本对话用户日志/NCU 截图。CUTLASS example 41 和 FlashAttention 上游用于设计对照，不等同于已确认的 NGC 内部版本。